

UNIWERSYTET ZIELONOGÓRSKI

Wydział Informatyki, Elektrotechniki i Automatyki

Praca magisterska

Kierunek: Informatyka

**WYKORZYSTANIE GŁĘBOKICH SIECI
NEURONOWYCH DO WSPOMAGANIA
DIAGNOSTYKI MEDYCZNEJ**

Krystian Dziędziola

Promotor:
dr inż. Artur Gramacki

Zielona Góra, czerwiec 2019

Streszczenie

Głównym celem pracy jest przedstawienie wyników przeprowadzonych badań dotyczących możliwości zastosowania głębokich sieci neuronowych do wspomagania diagnostyki medycznej. Przykładowym zadaniem, które zostało wybrane jako obiekt badań jest diagnozowanie stanów padaczkowych na podstawie odczytów z elektroencefalogramu (EEG).

// todo: uzupełnić

Słowa kluczowe: Sieci neuronowe, diagnostyka medyczna, EEG, deep learning.

Spis treści

1. Wstęp	1
1.1. Wprowadzenie	1
1.2. Cel i zakres pracy	1
1.3. Przegląd literatury	2
1.4. Struktura pracy	2
2. Wprowadzenie do głębokich sieci neuronowych	3
2.1. Sieci neuronowe a sztuczna inteligencja	3
2.2. Klasyczne sieci neuronowe	5
2.3. Deep learning, czyli głębokie sieci neuronowe	6
2.4. Architektury głębokich sieci neuronowych	8
2.4.1. Splotowe sieci neuronowe	8
2.4.2. Rekurencyjne sieci neuronowe	9
3. Omówienie wybranego problemu diagnostyki medycznej	11
3.1. Przedstawienie problemu	11
3.2. Dostępne dane	12
3.3. Oczekiwane rezultaty	12
4. Przegląd dostępnych bibliotek oraz narzędzi programistycznych	13
4.1. Dostępne narzędzia	13
4.2. Wybrany stos technologiczny	14
5. Próba rozwiązania problemu	15
5.1. Proces uczenia	15
5.1.1. Przygotowanie danych	15
5.1.2. Metoda oceny wyników	21
5.1.2.1. Hold-out	21
5.1.2.2. Walidacja krzyżowa	22
5.1.2.3. Implementacja walidacji	22
5.1.3. Uruchomienie uczenia właściwego	24
5.1.4. Budowa modelu	24
5.1.5. Sprawdzenie skuteczności	24
5.2. Monitorowanie	24
5.3. Wybór rodzaju sieci neuronowej	24
5.4. Optymalizacja	24
5.5. Ocena otrzymanych rezultatów	24
6. Zakończenie	25

A. Płyta DVD

26

Spis rysunków

2.1.	Porównanie klasycznego programowania z metodą uczenia maszynowego	4
2.2.	Zależność między sztuczną inteligencją, uczeniem maszynowym i sie- ciami neuronowymi	5
2.3.	Struktura prostej sieci neuronowej	5
2.4.	Schemat procesu uczenia głębokiej sieci neuronowej	7
2.5.	Dane liczbowe obrazka w formacie RGB	9
2.6.	Schemat działania sieci splotowej [1]	9
2.7.	Pętla w rekurencyjnej sieci neuronowej	10
5.1.	Podział danych na zbiory: treningowy, walidacyjny i testowy	22
5.2.	Podział danych według metody k-krotnej walidacji krzyżowe	23

Spis tabel

Rozdział 1

Wstęp

1.1. Wprowadzenie

Współczesna technologia sztucznej inteligencji, której dużą część stanowią sztuczne sieci neuronowe, pozwala na wykonywanie przez maszyny zadań, które do niedawna byli w stanie wykonywać tylko ludzie. Jednym z przykładów jest diagnostyka medyczna, która wymaga specjalistycznej wiedzy oraz doświadczenia.

Dzięki sztucznym sieciom neuronowym maszyna jest w stanie nauczyć się pewnych reguł, na podstawie których podejmuje decyzje, które mogą symulować ludzką inteligencję. W niektórych problemach maszyna jest w stanie podejmować poprawne decyzje z dokładnością dorównującą lub nawet przewyższającą zdolności człowieka. Dodatkowo może to zrobić w znacznie krótszym czasie.

// todo: uzupełnić

1.2. Cel i zakres pracy

Celem pracy jest próba wykorzystania głębokich sieci neuronowych do wspomagania diagnostyki medycznej dla wybranego problemu praktycznego oraz osiągnięcie możliwie najlepszych rezultatów.

Zakres pracy obejmuje:

- krótkie wprowadzenie w tematykę sieci głębokich oraz porównanie z klasycznymi sieciami neuronowymi,
- przegląd dostępnych bibliotek i narzędzi programistycznych dla sieci głębokich,
- omówienie praktycznego problemu z dziedziny diagnostyki medycznej i próba rozwiązania z wykorzystaniem sieci głębokich,
- przedstawienie szczegółów technicznych i implementacyjnych,
- wykonanie eksperymentów, ich ocena oraz sformułowanie wniosków końcowych.

1.3. Przegląd literatury

[2] [3] [4] // todo:

1.4. Struktura pracy

// todo:

Rozdział 2

Wprowadzenie do głębokich sieci neuronowych


2.1. Sieci neuronowe a sztuczna inteligencja

W ciągu ostatnich kilku lat sztuczna inteligencja stała się tematem dużego zainteresowania w nauce, technologii oraz życiu codziennym. Ma to miejsce za sprawą szerokiego spektrum jej zastosowań oraz możliwości wykorzystania do zadań, które do tej pory były niemal nieosiągalne przez maszyny. Są to m.in. autonomiczne pojazdy, inteligentni wirtualni asystenci, wspomaganie diagnostyki medycznej oraz wiele innych.

Sztuczna inteligencja datuje swoje początki na lata 50-te XX wieku kiedy to zaczęto prowadzić badania nad tym czy komputer jest w stanie nauczyć się "myśleć". Bardziej ścisłą definicją celu prowadzonych badań mogłaby być "próba automatyzacji zadań intelektualnych, które normalnie wykonywane są przez człowieka". Początkowo próby te były poczynione poprzez zaprogramowanie szeregu reguł, którymi miała posługiwać się maszyna w podejmowaniu swoich własnych decyzji. Jest to tzw. symboliczna sztuczna inteligencja (*ang. symbolic artificial intelligence*), czyli klasyczne podejście polegające na zaprogramowaniu określonego algorytmu działania. [5] Zauważono jednak, że zbiór określonych przez programistów reguł sprawdza się do rozwiązywania dobrze zdefiniowanych problemów logicznych takich jak np. gra w szachy. Takie podejście nie jest jednak wystarczające do osiągnięcia przez komputer umiejętności podejmowania decyzji, która mogłaby symulować ludzką inteligencję oraz wykonwania przez nią bardziej abstrakcyjnych zadań takich jak np. rozpoznawanie mowy, obrazu lub tłumaczenie języków.

Nasuwa się pytanie czy komputer jest w stanie wyjść poza ramy ściśle zdefiniowanych reguł i samemu nauczyć się w jaki sposób wykonywać określone zadania? Odpowiedzią na to pytanie oraz niedoskonałości klasycznego programowania było zastosowanie podejścia zwanego dziś uczeniem maszynowym (*ang. machine learning*). Polega ono na tym, że maszynie nie jest dostarczany ściśle określony algorytm działania, a jedynie przedstawiane są dane oraz wyniki jakie powinny powstać po przetworzeniu tychże danych. Maszyna ma za zadanie stworzyć swoje własne reguły, które będą odzwierciedlać sposób w jaki prawidłowo należy wykonać konkretne zadanie. Można więc powiedzieć, że w uczeniu maszynowym, maszyna jest uczona, a nie programowana. Pomimo tego, że uczenie maszynowe zaczęło się roz-

wijać dopiero w latach 90-tych bardzo szybko stało się popularne za sprawą tego, że przynosiło najlepsze wyniki spośród wszystkich podejść w dziedzinie sztucznej inteligencji. Różnicę pomiędzy klasycznym programowaniem a uczeniem maszynowym zaprezentowano na rysunku 2.1.



Rys. 2.1. Porównanie klasycznego programowania z metodą uczenia maszynowego

Mnogości zastosowań uczenia maszynowego dorównuje również ilość algorytmów, które są wykorzystywane w tym podejściu. Dostępnych jest wiele modeli, poczynając od bardzo prostych, kończąc na dosyć skomplikowanych. Kilka najczęściej używanych, to m.in.:

- **drzewa decyzyjne** (*ang. decision trees*),
- **algorytm k-średnich** (*ang. k-means*),
- **sztuczne sieci neuronowe** (*ang. artificial neural networks*). [6]

Przedmiotem tej pracy jest ostatnia z wymienionych metody, czyli sztuczne sieci neuronowe. Jest to zestaw algorytmów, który został zaprojektowany w sposób inspirowany działaniem ludzkiego mózgu. W rzeczywistości jednak, ich działanie nie jest do końca zgodne z tym, w jaki sposób działa umysł człowieka. Sieci neuronowe potrafią przyjmować dane w formie wektorów liczbowych, które mogą zawierać takie informacje jak np. obrazy, dźwięki, tekst lub szeregi czasowe. Na ich podstawie są w stanie dokonywać klasyfikacji, klasteryzacji oraz predykcji. Jednym z typów sztucznych sieci neuronowych są tzw. głębokie sieci neuronowe (*ang. deep neural networks*), które znacząco zwiększają możliwości klasycznych sieci neuronowych. Zostaną one omówione w rozdziale 2.3.


Można zauważyć, że sztuczna inteligencja jest pojęciem bardzo szerokim. W jej skład wchodzi różne metody m.in. uczenie maszynowe. Z kolei specyficznym podejściem w uczeniu maszynowym są sieci neuronowe. Zależności pomiędzy tymi pojęciami przedstawia rysunek 2.2.



Rys. 2.2. Zależność między sztuczną inteligencją, uczeniem maszynowym i sieciami neuronowymi

2.2. Klasyczne sieci neuronowe

Sieci neuronowe to dziedzina uczenia maszynowego, która jako model matematyczny podlegający uczeniu wykorzystuje strukturę sieci składającą się z wielu jednostek obliczeniowych zwanych neuronami. Neurony wykonują podstawowe obliczenia i ich wyniki przekazują do kolejnych neuronów. Operacje, które są wykonywane przez neurony to przeważnie sumowanie otrzymanych informacji oraz zastosowanie prostej, nieliniowej funkcji. W większości sieci neuronowych, neurony zgrupowane są w tzw. warstwy. Obliczenia wykonane przez jedną warstwę są przekazywane do kolejnej, która z kolei wykonuje obliczenia na otrzymanych wynikach. Ostatnia warstwa zwraca końcowy wynik, który jest interpretowany w różny sposób w zależności od wykonywanej operacji np. klasyfikacja lub regresja. Schemat prostej sieci neuronowej przedstawiony został na rysunku 2.3



Rys. 2.3. Struktura prostej sieci neuronowej

Pierwszą koncepcję neuronu datuje się na rok 1943, w którym to powstał model neuronu McCulloch-Pitts. Był on bardzo prosty w porównaniu do współczesnych sieci neuronowych, gdyż pozwalał jedynie na wykorzystanie wartości binarnych na wyjściu z neuronów. Każdy z nich sumował wartości wejściowe i przyrównywał je do zera. Dodatkowo nie istniała żadna reguła aktualizacji wewnętrznych wartości neuronów (tzw. wag), która jest niezbędna do prawidłowego przebiegu procesu adaptacji neuronu do nowych informacji. Bez takiej reguły wszystkie wagi neuronów

musiałyby być ustawiane ręcznie.

W latach 50-tych przedstawiony został perceptron, który jest najprostszą siecią neuronową składającą się z wielu neuronów McCullocha-Pittsa. Implementuje on algorytm uczenia nadzorowanego klasyfikatorów binarnych. Jest funkcją przynależności potrafiąca przydzielić jedną z dwóch klas do danych parametrów wejściowych. W perceptronie została przedstawiona prosta reguła służąca do aktualizacji wag dla kolejnych iteracji. Wzór na wagę w kroku $t + 1$ przedstawia się następująco:

$$w_i(t + 1) = w_i(t) + (d_j - y_j(t))x_{j,i} \quad (2.1)$$

gdzie w_i to waga i -tego neuronu, d_j to oczekiwana wartość dla j -tego wejścia, $y_i(t)$ oznacza wartość obliczoną z j -tego wejścia, natomiast $x_{j,i}$ jest i -tą wartością j -tego wejścia. Oznacza to, że przyszła wartość wagi neuronu obliczona jest przez dodanie błędu (różnicy między wartością oczekiwaną a obliczoną) pomnożonego przez wartość rzeczywistą do wartości aktualnej wagi. Reguła ta może być stosowana jedynie do uczenia jednowarstwowych sieci neuronowych, co znacznie ogranicza zakres jej zastosowań. Perceptron może więc być używany jedynie do problemów liniowo separowalnych.[3]

W latach 60-tych zostało matematycznie udowodnione, że sieć z pojedynczą warstwą nie posiada możliwości klasyfikowania problemów, które nie są liniowo separowalne. Przykładem jest funkcja alternatywy wykluczającej - XOR. Kolejne, bardziej skomplikowane problemy, których się podejmowano, takie jak m.in. rozpoznawanie mowy, kończyły się więc niepowodzeniem. Możliwość uczenia sieci wielowarstwowych była więc konieczna w dalszym rozwoju sieci neuronowych. W tej samej publikacji [4] zostało również udowodnione, że 2-warstwowa sieć jest w stanie zamodelować niemal każdą funkcję. W praktyce jest to jednak ciężkie do osiągnięcia.

W późniejszym okresie przedstawiony został algorytm wstecznej propagacji błędów (*ang. backpropagation*), który umożliwiał uczenie wielowarstwowych sieci neuronowych. Oparty jest on na minimalizacji wartości tzw. funkcji straty z wykorzystaniem optymalizacyjnej metody największego spadku. Błędy obliczane są na warstwie wyjściowej i przekazywane są wstecz, do warstw poprzedzających. Jest to możliwe dzięki wykorzystaniu tzw. metody łańcuchowej (*ang. chain rule*). Szczegóły dotyczące tego algorytmu zostały opisane w wielu publikacjach m.in. w [7]. Dzięki zastosowaniu tego typu podejścia osiągnięty został cel, który zakładał umożliwienie uczenia wielowarstwowych sieci neuronowych. Pozwoliło to w znaczącym stopniu przyspieszyć rozwój w tej dziedzinie.


Algorytm wstecznej propagacji błędów stał się najpopularniejszym i najbardziej skutecznym algorytmem do nauki sieci neuronowych. Ma on właśnie zastosowanie w głębokich sieciach neuronowych, które zostały opisane w rozdziale 2.3.

2.3. Deep learning, czyli głębokie sieci neuronowe

Deep learning to dziedzina uczenia maszynowego, która zakłada nowe podejście do nauki wzorców w danych. Kładzie ona nacisk przede wszystkim na naukę kolejnych warstw reprezentacji, które z każdą warstwą są coraz bardziej konkretne. Słowo "głębokie" (*ang. deep*) odnosi się głównie do ilości warstw, które składają się na model sieci. Ta cecha jest zwykle nazywana głębokością sieci (*ang. depth*). Nowoczesne

modele głębokich sieci neuronowych często uczą się dziesiątek, a czasem nawet setek kolejnych warstw reprezentacji danych. Każda z nich uczy się samodzielnie na podstawie przedstawionych im informacji.

Inne podejścia, takie jak np. klasyczne uczenie maszynowe skupia się na nauce jedynie jednej lub dwóch warstw reprezentacji danych, dlatego tego typu metody są często nazywane "płytким uczeniem" (*ang. shallow learning*). W deep learning'u jako model matematyczny prawie zawsze używa się sieci neuronowych, które składają się z nałożonych na siebie wielu warstw neuronów.



Rys. 2.4. Schemat procesu uczenia głębokiej sieci neuronowej

Każda z warstw posiada zestaw tzw. wag (*ang. weights*), które określają sposób w jaki interpretowane są dane wejściowe. Z technicznego punktu widzenia wagi są parametrami transformacji, które są wykonywane przez warstwy na danych wejściowych. W tym kontekście uczenie oznacza poszukiwanie odpowiedniego zestawu wag, który pozwoli na poprawne przekształcanie danych wejściowych w oczekiwane rezultaty. W głębokich sieciach neuronowych mogą istnieć miliony tego typu parametrów, więc znalezienie odpowiedniej wartości dla każdego z nich może być trudnym zadaniem, biorąc pod uwagę, że zmiana jednego parametru może mieć wpływ na zachowanie innych.

W celu poprawnej modyfikacji parametrów sieć musi obserwować wyniki wyjściowe i porównywać je z wynikami docelowymi, które dostarczone zostały w procesie

uczenia. Pomiar tego jak bardzo uzyskane wyniki różnią się od tych prawdziwych zajmuje się tzw. funkcja strat (*ang. loss function*). Zwraca ona konkretną wartość liczbową popełnionego błędu, który następnie może być minimalizowany w celu uzyskiwania coraz to lepszych wyników. Odbywa się to poczynając od warstwy ostatniej, kończąc na warstwie wejściowej stosując algorytm wstecznej propagacji błędów, który implementowany jest przez tzw. optymalizator (*ang. optimizer*). [7]

Początkowo wagi posiadają losowe wartości, które dostosowywane są w ramach wielu iteracji zwanych epokami uczącymi (*ang. epochs*). Przeważnie proces powtarzany jest dziesiątki razy na tysiącach przykładowych danych. Wybierany jest zestaw wag sieci, który posiada najmniejszą wartość funkcji strat, czyli jest najlepiej dostosowany do poprawnego przetwarzania danych wejściowych na wyjściowe. Cały proces uczenia głębokiej sieci neuronowej został zaprezentowany na rysunku 2.4.

Możliwość rozwoju głębokich sieci neuronowych była więc uwarunkowana powstaniem sprzętu o odpowiedniej mocy obliczeniowej, która umożliwiłaby wykonywanie tak dużej ilości obliczeń w skończonym czasie. Obecnie używane są do tego procesory kart graficznych (*GPU - ang. graphics processing unit*), które swoimi możliwościami znacznie przewyższają zwykłe procesory (*CPU - central processing unit*).

2.4. Architektury głębokich sieci neuronowych

Wyróżnia się 5 najczęściej stosowanych architektur głębokich sieci neuronowych. Są to:

- **Sieci splotowe** (*CNN - ang. Convolutional Neural Networks*)
- **Rekurencyjne sieci neuronowe** (*ang. Recurrent Neural Networks*)
- **ResNets** (*Residual Networks*)
- **Autoenkodery** (*ang. Autoencoders*)
- **GAN** (*ang. Generative Adversarial Networks*)


Zostaną omówione jedynie dwie pierwsze architektury, gdyż to one znalazły zastosowanie w niniejszej pracy.

2.4.1. Splotowe sieci neuronowe

Splotowe sieci neuronowe są niewątpliwie najpopularniejszą architekturą głębokich sieci neuronowych. Są one przeważnie używane do zadań związanych z rozpoznawaniem obrazów, jednak równie dobrze sprawdzają się w wielu innych dziedzinach.


Przewagą tego typu sieci nad klasycznymi sieciami neuronowymi jest możliwość rozpoznawania tymczasowych oraz przestrzennych zależności pomiędzy danymi. Jest to możliwe, dzięki temu, że dane które trafiają do sieci mogą posiadać strukturę wielowymiarową. Przykładowo, obrazki zapisane w formacie RGB są 3-wymiarową macierzą przechowującą informację o wartościach koloru każdego z pikseli 2.5.

Na danych przestrzennych wykonywane są operacje takie jak: konwolucja (*ang. convolution*), zmniejszanie rozmiaru danych (*ang. subsampling*) oraz aktywacja (*ang.*



Rys. 2.5. Dane liczbowe obrazka w formacie RGB

activation). Znalezione cechy są następnie podawane na wejście klasycznej sieci, gdzie neurony połączone są każdy z każdym (*ang. fully connected*), która wykonuje ostateczne operacje i zwraca wynik końcowy. Działanie sieci splotowej polega na tworzeniu kolejnych tzw. map cech (*ang. feature map*), które są abstrakcyjnymi reprezentacjami danych umożliwiającymi wychwycenie podobieństw i zależności pomiędzy danymi. Szczegółowy opis sposobu działania tych operacji został przedstawiony m.in. w [2] oraz [7]. Przykładowy schemat splotowej sieci neuronowej składający się z kilku warstw konwolucyjnych połączonych z warstwami zmniejszającymi rozmiar danych (tzw. *pooling*'iem), która została zakończona dwoma warstwami sieci *FC* - *fully connected* przedstawiony jest na rysunku 2.6.



Rys. 2.6. Schemat działania sieci splotowej [1]


Zaletą tego typu sieci jest bez wątpienia możliwość przetwarzania wielowymiarowych danych, dzięki czemu są one w stanie odnajdywać przestrzenne zależności pomiędzy nimi, co przekłada się na ich wysoką skuteczność i wszechstronność.

2.4.2. Rekurencyjne sieci neuronowe

Rekurencyjne sieci neuronowe są często używane do rozwiązywania problemów, gdzie wykorzystywane są dane sekwencyjne. W praktyce znajdują one zastosowanie w takich problemach jak np. przetwarzanie języka naturalnego, synteza mowy czy automatyczne tłumaczenie języków.

Idea działania rekurencyjnych sieci neuronowych polega na zapamiętywaniu pewnego ciągu sekwencji i dokonywanie wyborów nie tylko na podstawie aktualnych

danych, ale również tych, które były przetwarzane poprzednio. Jest to realizowane za pomocą wewnętrznej pętli, która polega na przekazywaniu wyników z danej warstwy jako dodatkowych danych wejściowych podczas kolejnej iteracji. Schemat pętli zaprezentowany został na rysunku 2.7.



Rys. 2.7. Pętla w rekurencyjnej sieci neuronowej

Zaletą rekurencyjnych sieci neuronowych jest to, że współdzielą one jeden zestaw parametrów we wszystkich krokach, dzięki temu pozwala to zredukować ich ilość. Mogą być one również używane w połączeniu z sieciami splotowymi.

Do wad należy m.in. to, że nie są one w stanie zapamiętywać zbyt długich sekwencji. Dodatkowo ich głębokość nie może być zbyt duża, ponieważ używane funkcje aktywacji powodują, że gradient zmian zanika po przejściu przez kilka warstw.

Rozdział 3

Omówienie wybranego problemu diagnostyki medycznej

3.1. Przedstawienie problemu

W celu sprawdzenia możliwości zastosowania głębokich sieci neuronowych do diagnostyki medycznej został wybrany problem **wykrywania napadów padaczki na podstawie odczytów z elektroencefalogramu (EEG)**.

Padaczka (zwana również epilepsją) to grupa przewlekłych zaburzeń neurologicznych, które charakteryzują się napadami padaczkowymi. Napady są powodowane przejściowymi zaburzeniami pracy mózgu polegającymi na samorzutnych wyładowaniach bioelektrycznych w komórkach nerwowych mózgu. Występują one ze zróżnicowaną siłą, od krótkich i ledwo zauważalnych, aż do długich, silnych wstrząsów. Może towarzyszyć im utrata świadomości oraz drgawki. Epilepsja jest nieuleczalna, jednak w wielu przypadkach może być kontrolowana lekami. Cierpi na nią ok. 1% ludzi na całym świecie, czyli ok. 65 milionów [8].

Podczas standardowego badania aktywność mózgu monitorowana jest za pomocą elektroencefalogramu. Odczyty fal mózgowych tworzone są na podstawie sygnałów odbieranych przez elektrody umieszczane na głowie pacjenta. Aktualnie odczyty muszą być analizowane przez wykwalifikowanego neurologa, który jest w stanie rozpoznać charakterystyczne wzorce wskazujące na występowanie choroby. Wizualna diagnostyka odczytów jest jednak niezwykle pracochłonna i wymaga specjalistycznej wiedzy. Skutkiem tego mogą być limity pacjentów, których badania mogą zostać przeanalizowane. Ograniczenia te mogą być rozwiązane poprzez próbę automatycznego wykrywania napadów padaczkowych przez maszynę.

Problem automatycznego wykrywania ataków był już wielokrotnie badany. Często do rozwiązania problemów używane były algorytmy, które używały specjalnie przygotowanych zestawów cech charakteryzujących ataki. Znanym faktem jest jednak to, że napady padaczki mogą być niezwykle zróżnicowane. Tyczy się to zarówno przypadków, w których porównywane są charakterystyki ataków różnych pacjentów, jak i tych, które występują podczas badania jednego chorego. Zostały podejmowane również próby wykorzystania głębokich sieci neuronowych, które byłyby w stanie wykryć w danych bardziej generyczne wzorce pozwalające na klasyfikację z większą dokładnością i odpornością na zróżnicowanie danych. Sposób, oraz wyniki przeprowadzonych w ten sposób badań można znaleźć m.in. w [9], [10] oraz [11].

3.2. Dostępne dane

Badania opisane w niniejszej pracy zostały przeprowadzone na danych udostępnionych przez Szpital Wojewódzki w Zielonej Górze. Dostępne są odczyty 104 chorych pacjentów w różnym wieku, każde trwające około 15 minut. Zostały one przeanalizowane przez neurologa, który oznaczył punkty w czasie, w których doszło do ataków.

Odpowiednio przygotowane odczyty wraz z wynikami badań posłużą jako dane, na podstawie których zostaną przeprowadzone eksperymenty polegające na próbie nauki głębokiej sieci neuronowej do automatycznego rozpoznawania stanów padaczkowych.

3.3. Oczekiwane rezultaty

Wymienione publikacje naukowe przedstawiają obiecujące wyniki. Niektóre z nich prezentują rezultaty na poziomie nawet ok. 90% skuteczności. Badania te zostały jednak przeprowadzone na zupełnie innych danych. Często używana jest ogólnie dostępna baza CHB-MIT (Children's Hospital of Boston-Massachusetts Institute of Technology). Nie są znane również szczegóły implementacyjne, dlatego opracowane zostanie własne rozwiązanie analizowanego problemu.

Rezultatem oczekiwanym w tej pracy jest osiągnięcie wyników świadczących o tym, że technologię deep learning'u oraz zaproponowane rozwiązanie można z powodzeniem zastosować również do posiadanej bazy odczytów. Wyniki przewyższające 70% skuteczności powinny być dobrym wyznacznikiem pomyślności wykonanych badań.

Rozdział 4

Przegląd dostępnych bibliotek oraz narzędzi programistycznych

4.1. Dostępne narzędzia

Istnieje niezliczona ilość narzędzi umożliwiających tworzenie oraz naukę głębokich sieci neuronowych. Do tych najbardziej popularnych zalicza się m.in.:

- **TensorFlow** - najczęściej używana biblioteka do deep learning'u stworzona przez Google. Jest ona używana m.in. przez takie firmy jak Airbus, Twitter oraz IBM. Google wykorzystuje ją również w swoich produktach np. tłumacz Google zbudowany jest na bazie TensorFlow. Rekomendowanym językiem jest Python, jednak istnieje możliwość używania języków Java, C oraz Go.
- **Keras** - biblioteka dostarczająca wysokopoziomowe API umożliwiające tworzenie sieci neuronowych w prosty sposób. Keras sam w sobie nie posiada silnika umożliwiającego tworzenia sieci neuronowych, jednak używa jednej z wybranych bibliotek (TensorFlow, CNTK lub Theano). Biblioteka jest napisana w Pythonie i ten język jest zalecany do użytku, jednak istnieje możliwość użycia również języka R.
- **Theano** - biblioteka dedykowana dla Pythona umożliwiająca tworzenie sieci neuronowych może być używana w połączeniu z biblioteką Keras.
- **Caffe** - biblioteka stworzona przez zespół Berkeley AI Research (BAIR). Została napisana w C++, jednak umożliwia również korzystanie z Matlab'a oraz Python'a.
- **Deeplearning4j** - biblioteka napisana w Javie, kompatybilna ze wszystkimi językami uruchamianymi na wirtualnej maszynie Javy (JVM) m.in. Java, Groovy, Scala czy Kotlin. Jest bardziej ukierunkowana na użycie w aplikacjach biznesowych, niż naukowo-badawczych.

Wszystkie wymienione biblioteki są dostępne za darmo.

4.2. Wybrany stos technologiczny

Stos technologiczny wybrany do wykonania badań w tej pracy to:

- **Python** - najbardziej popularny język programowania do deep learning'u, bardzo dobrze przystosowany do zastosowań naukowych.
- **Keras/TensorFlow** - najczęściej wykorzystywany zestaw bibliotek posiadający bardzo dobrą dokumentację, opisywany w wielu poradnikach. Wspiera również możliwość wykonywania obliczeń na karcie graficznej. Dostarcza dodatkowy zestaw narzędzi umożliwiających monitorowania sieci m.in. TensorBoard.
- **Nvidia cuDNN** - biblioteka umożliwiająca wykonywanie obliczeń na karcie graficznej podczas nauki sieci neuronowych. Jej używanie jest bardzo zalecane, gdyż umożliwia o wiele szybsze przetwarzanie danych. Wymagane jest posiadania odpowiedniej karty graficznej wspierającej tę technologię.
- **Jupyter Notebook** - środowisko programistyczne umożliwiające pracę w językach Julia, Python oraz R.
- **Docker** - narzędzie służące do konteneryzacji. Umożliwia uruchamianie całego środowiska w odizolowanych kontenerach za pomocą dostępnych publicznie obrazów bez konieczności instalacji w systemie żadnych dodatkowych narzędzi.

Rozdział 5

Próba rozwiązania problemu

5.1. Proces uczenia

Proces uczenia sieci neuronowej stworzony został w środowisku Jupyter Notebook, które umożliwia tworzenie dokumentów zawierających opisy, wykresy oraz wykonywalne kody źródłowe. Nazwa Jupyter wzięła się z tego, że środowisko umożliwia pracę w trzech językach: Julia, Python oraz R.

Dokument składa się z wielu komórek, które mogą być wywoływane niezależnie. Przewagą kodu pisanego w tym środowisku nad tradycyjnymi skryptami jest oferowana przez nie możliwość zapamiętywania stanu zmiennych. Dzięki temu nie ma potrzeby każdorazowego wywoływania całego kodu, a jedynie fragmentów, które w danej chwili są potrzebne np. jednorazowe przygotowanie danych, a następnie wykonywanie jedynie procesu uczenia.

Proces uczenia składa się z kilku kroków:

- pobranie i przygotowanie danych za pomocą przygotowanych skryptów 5.1.1
- podział danych na zbiory służące do nauki oraz testowania przy pomocy *k*-krotnej walidacji krzyżowej (*ang. k-fold cross-validation*) 5.1.2
- utworzenie modelu sieci neuronowej 5.1.4
- rozpoczęcie uczenia modelu 5.1.3
- sprawdzenie skuteczności i przedstawienie wyników 5.1.5

Wszystkie wymienione kroki przedstawiają pełen proces uczenia, który pokazuje z jaką dokładnością model jest w stanie wykrywać stany padaczkowe.

5.1.1. Przygotowanie danych

W celu wykorzystania dostępnych danych w procesie uczenia sieci neuronowej należy je najpierw odpowiednio przygotować. Dostarczone zostały dane w postaci plików tekstowych z liczbami reprezentującymi wartości zmierzone przy pomocy elektroencefalogramu. W poszczególnych kolumnach znajdują się wartości odpowiadające konkretnym kanałom (*EEG_FP1_F3*, *EEG_FP2_F4* itd.). Ostatnia kolumna (o nagłówku *t*) przedstawia czas w sekundach, w którym miał miejsce pomiar.

Dostępne są dane 104 pacjentów, u których wystąpiły ataki. Każdy z nich posiada odczyty wykonane z częstotliwością 500Hz przez blisko 15 minut. Jest to około 450 000 linii w każdym pliku. Dane zajmują 6,5 GB.

Fragment jednego z plików z danymi wygląda następująco:

Listing 5.1. Dane liczbowe z odczytu EEG

1	"EEG_FP1_F3"	"EEG_FP2_F4"	"EEG_F3_C3"	"EEG_F4_C4"	"EEG_C3_P3"						
	"EEG_C4_P4"	"EEG_P3_01"	"EEG_P4_02"	"EEG_FP1_F7"	"EEG_FP2_F8"						
	"EEG_F7_T3"	"EEG_F8_T4"	"EEG_T3_T5"	"EEG_T4_T6"	"EEG_T5_01"						
	"EEG_T6_02"	"t"									
2	-1.7032	-3.3727	5.9014	2.512	2.6404	4.0193	16.9162	35.4401	5.3506	1.1355	-1.0843
	-3.9932	9.4594	14.8409	10.0322	26.6143	0					
3	-3.1702	-4.5883	5.8762	2.9638	3.5952	3.9019	17.1137	36.3634	4.3875	0.543	-1.356
	-4.5697	10.309	14.1082	10.0724	28.5593	0.002					
4	-4.2669	-5.2157	5.6852	3.1698	4.0053	3.6091	16.4135	36.7024	2.9881	0.4522	-1.7584
	-5.4206	11.1134	13.3778	9.4926	29.8509	0.004					
5	-4.8106	-5.2287	5.2889	2.6745	3.714	3.0257	14.9097	36.4086	1.6189	0.2802	-2.1206
	-6.4522	11.2876	12.7727	8.3198	30.2831	0.006					
6	-5.0684	-5.1176	4.7665	1.7354	2.9116	2.354	12.7327	35.6144	0.5718	-0.618	-2.57
	-7.3378	10.6144	12.2487	6.7256	30.2934	0.008					
7	-5.3637	-5.1568	4.399	1.03	1.764	1.9509	10.2011	34.6652	-0.2974	-2.1804	-3.1603
	-7.7025	9.3368	11.727	5.1179	30.6433	0.01					

Dodatkowo dostarczony został plik przechowujący wyznaczone przez lekarza momenty wystąpienia ataków dla każdego z pacjentów. Plik w kolejnych wierszach zawiera punkty w czasie rozdzielone przecinkami (w sekundach). Każdy wiersz odpowiada jednemu pacjentowi, dlatego plik zawiera 104 wiersze. Fragment pliku z czasami wystąpienia ataków:

Listing 5.2. Punkty w czasie wystąpienia ataków

1	835,853,865,873,889,908
2	18,48,110,309,466,618,757
3	216,239
4	44,329,501,559,622
5	36,190,406,576,714,754
6	158,510,917
7	622,653,676,737

W celu wykorzystania przedstawionych danych w procesie uczenia sieci neuronowej muszą zostać one odpowiednio przygotowane. Wybrane podejście zakłada podzielenie danych na okna czasowe o określonej długości. Znane są jedynie początki ataków, jednak nie wiadomo jak długo trwały. Długość okna czasowego, według którego podzielone zostaną dane będzie więc jednym z parametrów, który należy dobrać w celu uzyskania najlepszych rezultatów.

Do przygotowania danych stworzony został skrypt, który wykonuje następujące czynności:

- wczytanie danych pacjentów oraz informacji o atakach
- przetworzenie danych do częstotliwości 100Hz
- podział danych na okna czasowe o długości przekazanej jako parametr (w sekundach)
- normalizacja danych - średnia 0, odchylenie standardowe 1
- konwersja danych dotyczących ataków na postać tzw. "jeden z n" (*ang. one-hot encoding*)

- wyświetlanie informacji o postępie przetwarzanych plików
- zapis pobranych danych do plików tymczasowych umożliwiających szybszy odczyt

Technicznie skrypty zostały podzielone na 2 pliki:

- `data_reader.py`
- `chunks_creator.py`

Pierwszy z nich zajmuje się wczytywaniem i korzysta z drugiego w celu stworzenia okien czasowych. Główną funkcją dostarczaną przez skrypt, która umożliwia wykonanie wszystkich wymienionych wyżej czynności jest `get_data()`. Jako parametr przyjmuje ona czas w sekundach, który oznacza długość okna czasowego. Znajduje się ona na końcu pliku, gdyż z uwagi na specyfikę języka wszystkie wykorzystywane przez nią funkcje muszą być wcześniej zadeklarowane. Kod skryptu pobierającego dane rozszerzony o komentarze opisujące poszczególne kroki zaprezentowany został na listingu 5.3.

Listing 5.3. `data_reader.py`

```
1 import os
2 import numpy as np
3 import pickle
4
5 from chunks_creator import prepare_chunks
6 from chunks_creator import flatten_chunks
7
8 from sklearn.preprocessing import StandardScaler
9
10 INPUT_DATA_FILE_PATH='tmp/input-{}sec.pkl'
11
12 DATA_FREQUENCY = 500
13 SAMPLING_RATE = 5
14 FREQUENCY_TO_SAMPLING_RATIO = DATA_FREQUENCY // SAMPLING_RATE
15
16
17 # Konwertuje plik z danymi pacjenta z postaci tekstowej do tablicowej oraz zmienia
   częstotliwość próbkowania do 100Hz
18 def parse_file(file, sampling_rate):
19     lines = file.split('\n')
20     headers = lines[0].split('\t')
21     # to one before last because the last one is empty
22     data = lines[1:-1]
23
24     number_of_lines = len(data)
25
26     float_data = np.zeros((number_of_lines, len(headers)))
27     for line_number, line in enumerate(data):
28         values = [float(value) for value in line.split('\t')]
29         float_data[line_number, :] = values
30
31     return float_data[::sampling_rate], headers
32
33
34 # Wczytuje dane pacjentów z dysku
35 def read_input_files(end, data_path, sampling_rate):
36     input_path = os.path.join(data_path, 'input_500Hz/sick')
37     input_file_names = os.listdir(input_path)
38     input_file_names.sort(key=int)
39
40     start = None
41
42     files_content = []
43     for file_name in input_file_names[start:end]:
```



```

44     file_path = os.path.join(input_path, file_name)
45     file = open(file_path, 'r')
46     (columns, headers) = parse_file(file.read(), sampling_rate)
47     print('Loaded input file:', file_name)
48     file.close()
49     files_content.append(columns)
50     print('--Input files loaded--')
51     return files_content, headers
52
53
54 def create_target_index(value, frequency_to_sampling_ratio):
55     value = int(value)
56     return int(value * frequency_to_sampling_ratio)
57
58
59 # Odczytuje informacje dotyczące czasów ataków i konwertuje do postaci one-hot
60 def read_target_files(end, data_path, sampling_rate, data_frequency):
61     frequency_to_sampling_ratio = data_frequency // sampling_rate
62     targets_path = os.path.join(data_path, 'targets')
63     targets_file_name = os.listdir(targets_path)[0]
64     targets_file_path = os.path.join(targets_path, targets_file_name)
65
66     file = open(targets_file_path, 'r')
67     targets_content = file.read()
68     file.close()
69
70     lines = targets_content.split('\n')[:-1]
71     targets = []
72     for number, line in enumerate(lines, 1):
73         targets.append([(int(value), create_target_index(value,
74             frequency_to_sampling_ratio)) for value in line.split(',')])
74     print('--Target files loaded--')
75     return targets[:end]
76
77
78 # Pobiera dane pacjentów oraz czasy ataków
79 def read_data(data_path, sampling_rate, data_frequency, end=104):
80     (input_data, headers) = read_input_files(end, data_path, sampling_rate)
81     targets_data = read_target_files(end, data_path, sampling_rate, data_frequency)
82
83     return input_data, targets_data, headers
84
85
86 # Odczytuje dane i zapisuje zmienne do pliku tymczasowego
87 def load_data_to_file(chunk_size_in_seconds):
88     (input_data, target, headers) = read_data(data_path='data',
89         sampling_rate=SAMPLING_RATE,
90         data_frequency=DATA_FREQUENCY)
91
92     with open(INPUT_DATA_FILE_PATH.format(chunk_size_in_seconds), 'wb') as
93         input_variable_file:
94         pickle.dump([input_data, target, headers], input_variable_file)
95
96     del input_data, target, headers
97
98 # Normalizuje dane używając obiektu StandardScaler(). Zwrócone dane posiadają średnią 0
99     oraz odchylenie standardowe 1.
100 def normalize(x, y):
101     scalers = {}
102     for channel_number in range(x.shape[1]):
103         scalers[channel_number] = StandardScaler()
104         x[:, channel_number, :] = scalers[channel_number].fit_transform(x[:,
105             channel_number, :])
106     return x, y.astype(int)
107
108 # Pobiera zmienne z danymi z utworzonego pliku tymczasowego
109 def load_input_data(chunk_size_in_seconds):
110     with open(INPUT_DATA_FILE_PATH.format(chunk_size_in_seconds), 'rb') as
111         input_data_file:
112         input_data, target, headers = pickle.load(input_data_file)

```

```

112     return input_data, target, headers
113
114
115 # Pobiera dane wykorzystując funkcję load_input_data() i wywołuje funkcję
    prepare_chunks() z pliku chunks_creator.py w celu utworzenia okien czasowych z
    danymi. Utworzone porcje danych są następnie poddawane normalizacji.
116 def prepare_data(chunk_size_in_seconds):
117     input_data, target, headers = load_input_data(chunk_size_in_seconds)
118
119     chunks_input, chunks_target = prepare_chunks(input_data,
120                                                  target,
121                                                  chunk_size_in_seconds=chunk_size_in_seconds,
122                                                  ratio=FREQUENCY_TO_SAMPLING_RATIO)
123     x, y = flatten_chunks(chunks_input, chunks_target)
124     x, y = normalize(x, y)
125
126     return x, y
127
128
129 # Główna funkcja skryptu, która zwraca odpowiednio przygotowane dane. Przy pierwszym
    uruchomieniu wczytuje dane z dysku do zmiennych i zapisuje je do pliku
    tymczasowego. Odczyt zmiennych z danymi z pliku binarnego umożliwia szybszy dostęp
    przy kolejnych uruchomieniach, gdyż otwieranie dużych plików tekstowych jest
    czasochłonne.
130 def get_data(chunk_size_in_seconds):
131     file_exists = os.path.isfile(INPUT_DATA_FILE_PATH.format(chunk_size_in_seconds))
132
133     if not file_exists:
134         load_data_to_file(chunk_size_in_seconds)
135
136     return prepare_data(chunk_size_in_seconds)

```

Funkcja *prepare_data()* w powyższym skrypcie korzysta z osobnego pliku o nazwie *chunks_creator.py*, w którym zostały zdefiniowane funkcje tworzące okna czasowe z danymi. Dla danych każdego z pacjentów tworzonych jest $2 * n$ okien czasowych, gdzie n oznacza ilość zdiagnozowanych ataków.

Porcje danych zawierające ataki tworzone są na początku każdego z nich i trwają przez określony czas podany w parametrze. Następnie tworzone jest n kolejnych porcji danych zawierających dane liczbowe z okresu, w którym nie wystąpił atak. Utworzone okna czasowe zawierają więc proporcjonalną ilość danych z atakami oraz bez. Dodatkowo tworzona jest tablica zawierająca informacje o tym czy dla danego okna czasowego wystąpił (*wartość 1*) lub nie wystąpił (*wartość 0*) atak.

Implementacja skryptu odpowiadającego za przetwarzanie danych do postaci okien czasowych przedstawiona została na listingu 5.4.

Listing 5.4. chunks_creator.py

```

1 import random
2 import numpy as np
3
4
5 # Tworzy porcje danych, w których wystąpiły ataki.
6 def create_chunks_with_seizures(patient_data, seizure_seconds, chunk_size):
7     number_of_chunks = len(seizure_seconds)
8
9     chunks_input = np.zeros((number_of_chunks, chunk_size, 17))
10    chunks_target = np.zeros(number_of_chunks)
11
12    for seizure_number in range(0, number_of_chunks):
13        (seizure_time, seizure_index) = seizure_seconds[seizure_number]
14        chunk_start_index = seizure_index
15        chunk_end_index = chunk_start_index + chunk_size
16        chunks_input[seizure_number] = patient_data[chunk_start_index:chunk_end_index,
            : ]
17        # atak oznaczony wartością '1'
18        chunks_target[seizure_number] = 1
19

```

```

20     return (chunks_input, chunks_target)
21
22
23 # Sprawdza czy podany fragment znajduje się w zasięgu ataku.
24 def is_in_seizure_range(index, seizure_seconds, chunk_size):
25     for (seizure_time, seizure_index) in seizure_seconds:
26         seizure_start_index = seizure_index
27         seizure_end_index = seizure_start_index + chunk_size
28         if index in range(seizure_start_index, seizure_end_index):
29             return True
30
31     return False
32
33
34 # Tworzy początek pojedynczej porcji danych, który wybierany jest losowo, jednak
35   sprawdzane jest, aby nie zawierała ona momentów, w których wystąpił atak.
36 def create_non_seizure_data_start_index(data_size, chunk_size, seizure_seconds):
37     start_index = random.randint(0, data_size - chunk_size)
38
39     while (is_in_seizure_range(start_index, seizure_seconds, chunk_size)):
40         start_index = random.randint(0, data_size - chunk_size)
41
42     return start_index
43
44 # Tworzy porcje danych, w których nie wystąpiły ataki.
45 def create_chunks_without_seizures(patient_data, seizure_seconds, chunk_size):
46     number_of_chunks = len(seizure_seconds)
47
48     chunks_input = np.zeros((number_of_chunks, chunk_size, 17))
49     chunks_target = np.zeros(number_of_chunks)
50     (data_size, channels) = patient_data.shape
51
52     for chunk_number in range(0, number_of_chunks):
53         chunk_start_index = create_non_seizure_data_start_index(data_size, chunk_size,
54             seizure_seconds)
55
56         chunk_end_index = chunk_start_index + chunk_size
57         chunks_input[chunk_number] = patient_data[chunk_start_index:chunk_end_index, :]
58         # brak ataku oznaczone wartością '0'
59         chunks_target[chunk_number] = 0
60
61     return (chunks_input, chunks_target)
62
63 # Przystosowuje ilość wymiarów danych do procesu uczenia sieci neuronowej.
64 def flatten_chunks(chunks_input, chunks_target):
65     train_input = []
66     train_target = []
67
68     for patient_number in range(0, len(chunks_input)):
69         patient_data = chunks_input[patient_number]
70         patient_targets = chunks_target[patient_number]
71         for chunk_number in range(0, len(patient_data)):
72             train_input.append(patient_data[chunk_number])
73             train_target.append(patient_targets[chunk_number])
74
75     train_input = np.array(train_input)
76     train_target = np.array(train_target)
77
78     train_input = train_input[:, :, :-1]
79
80     return train_input, train_target
81
82
83 # Główna funkcja skryptu zwracająca okna czasowe stworzone z danych pacjentów w postaci
84   wielowymiarowej tablicy oraz tablicę zawierającą informacje o wystąpieniu ataków.
85 def prepare_chunks(input, target, chunk_size_in_seconds, ratio):
86     chunk_size = chunk_size_in_seconds * ratio
87     chunks_input = []
88     chunks_target = []
89
90     for patient_number in range(0, len(input)):

```

```
90     patient_chunks_input = []
91     patient_chunks_target = []
92     seizure_seconds = target[patient_number]
93     patient_data = input[patient_number]
94     (seizure_chunks_input, seizure_chunks_target) =
95         create_chunks_with_seizures(patient_data, seizure_seconds, chunk_size)
96     patient_chunks_input.extend(seizure_chunks_input)
97     patient_chunks_target.extend(seizure_chunks_target)
98
99     (non_seizure_chunks_input, non_seizure_chunks_target) =
100         create_chunks_without_seizures(patient_data, seizure_seconds, chunk_size)
101     patient_chunks_input.extend(non_seizure_chunks_input)
102     patient_chunks_target.extend(non_seizure_chunks_target)
103
104     chunks_input.append(np.array(patient_chunks_input))
105     chunks_target.append(np.array(patient_chunks_target))
106
107     return np.array(chunks_input), np.array(chunks_target)
```

Przedstawione skrypty umożliwiają pobranie odpowiednio przygotowanych danych, które następnie mogą być użyte w procesie uczenia sieci neuronowej.


5.1.2. Metoda oceny wyników

Do zweryfikowania skuteczności modelu wymagane jest podzielenie danych na odpowiednie zbiory. Korzystanie z jednego, identycznego zbioru danych do nauki oraz testowania jest błędem, gdyż może wprowadzić złudne wrażenie, że model posiada bardzo dobrą skuteczność. Sieć neuronowa, której działanie weryfikowane jest na danych, które posłużyły do nauki będzie posiadać skuteczność bliską 100%. Dzieje się tak dlatego, że umie one rozpoznawać te konkretne dane, gdyż zna dla nich wartości wyjściowe, które podane zostały podczas nauki. W ten sposób nauczony model będzie natomiast posiadał bardzo niską skuteczność, gdy na jego wejście podane zostaną dane, które nigdy wcześniej nie zostały mu przedstawione. W każdym rodzaju uczenia maszynowego dąży się do uzyskania jak największej zdolności generalizacji, czyli skuteczności klasyfikacji danych, które nie zostały nigdy wcześniej przekazane do modelu. Przeciwnieństwem tego jest tzw. "nadmierne dopasowanie" (*ang. overfitting*), czyli sytuacja, w której model zbyt mocno dopasowuje się do danych uczących, co powoduje bardzo słabą zdolność generalizacji. Zjawisko to jest głównym problemem podczas uczenia modelu.

5.1.2.1. Hold-out

Podstawowym sposobem oceny wyników jest podzielenie danych na dwa zbiory: treningowy oraz testowy (*ang. hold-out*). Można dzielić je w różnych proporcjach np. 80/20, 90/10, 95/5 itp. w zależności od ilości posiadanych danych. Przy niewielkich zbiorach wydzielenie zbyt dużej liczby danych do zbioru testowego może powodować niedobory w procesie nauki. Wydzielenie jedynie dwóch zbiorów danych nie rozwiązuje jednak do końca problemu *overfitting*'u, gdyż zbyt częsta zmiana modelu i sprawdzanie jego skuteczności na danych testowych może spowodować zbyt duże dopasowanie do zbioru testowego. Z tego względu często stosowany jest dodatkowy zbiór walidacyjny (*ang. validation set*). W tym podejściu model uczony jest na danych treningowych, sprawdzany na danych walidacyjnych i na podstawie tych wyników wprowadza się modyfikacje w modelu. Zbiór testowy służy jedynie do ostatecznego sprawdzenia skuteczności modelu, gdyż są to dane, które nigdy wcześniej

nie zostały użyte w procesie nauki. Dane dzielone są w proporcjach np. 80/10/10, 90/5/5. Schemat tego podejścia przedstawiony jest na rysunku 5.1



Rys. 5.1. Podział danych na zbiory: treningowy, walidacyjny i testowy

Metoda ta rozwiązuje problem zbyt dużego dopasowywania się do zbioru testowego, jednak również posiada drugą wadę poprzedniego rozwiązania. Przy niewielkiej ilości danych wydzielanie osobnych zbiorów może spowodować, że zbiór uczący będzie zbyt mały. W celu uniknięcia tego problemu można zastosować tzw. walidację krzyżową i jej iteracyjne rozszerzenie.

5.1.2.2. Walidacja krzyżowa

Kolejną metodą walidacji jest tzw. k -krotna walidacja krzyżowa (*ang. k -fold cross-validation*). Tak samo jak w przypadku metody *holdout* należy najpierw wydzielić zbiór testowy, który nie będzie brał udziału w procesie uczenia i walidacji. Pozostałe dane dzielone są na k zbiorów, przeważnie jest to $k = 5$ lub $k = 10$. Następnie k -krotnie powtarzany jest proces wyboru jednego i -tego zbioru, gdzie i oznacza kolejne liczby z przedziału $\langle 1; k \rangle$. Zbiór o numerze i wybierany jest jako zbiór walidacyjny, natomiast reszta $k - 1$ zbiorów służy jako dane uczące. Należy pamiętać, żeby w każdym przebiegu uczyć nową instancję modelu. W rezultacie model uczony jest k -krotnie na różnych kombinacjach danych. Jako wynik końcowy brana jest pod uwagę średnia skuteczność wszystkich modeli. Sposób podziału danych w tej metodzie ilustruje rysunek 5.2.

Przedstawioną metodę można rozszerzyć do jej iteracyjnej wersji polegającej na tym, że cały proces k -krotnej walidacji krzyżowej wykonywany jest n razy. Dodatkowo po każdej iteracji można zastosować mieszanie danych. Walidacja tą metodą co prawda trwa o wiele dłużej, gdyż model walidowany jest $k * n$ razy, jednak pozwala uzyskać bardziej wiarygodne wyniki, gdy nie jest dostępna zbyt duża liczba danych.

5.1.2.3. Implementacja walidacji

Zaimplementowane zostały obie metody podziału danych, jednak ze względu na swoje zalety metody iteracyjnej k -krotnej walidacji krzyżowej to właśnie ona została użyta do walidacji w procesie uczenia. Podział danych według obu metod został wykonany za pomocą biblioteki *sklearn*, która dostarcza przygotowane do tego celu funkcje 5.5.

Listing 5.5. Podział danych na zbiory


```
12                                     x=x_train,
13                                     y=y_train,
14                                     epochs=100)
15
16     accuracy = [row[1] for row in best_model_score]
17
18     avg_accuracy = np.mean(accuracy)
19     print("Best models average validation accuracy: {}".format(round(avg_accuracy, 6)))
20
21     avg accuracies.append(avg_accuracy)
22
23 grand_mean_avg = np.mean(avg accuracies)
24 print("~~~Grand mean of average accuracy: {}".format(round(grand_mean_avg, 6)))
```

Do uruchamiania procesu uczenia używana jest funkcja *run_pipeline*, która szczegółowo opisana zostanie w rozdziale 5.1.3.

5.1.3. Uruchomienie uczenia właściwego

5.1.4. Budowa modelu

5.1.5. Sprawdzenie skuteczności

5.2. Monitorowanie

5.3. Wybór rodzaju sieci neuronowej

5.4. Optymalizacja

5.5. Ocena otrzymanych rezultatów

Rozdział 6

Zakończenie

Dodatek A

Płyta DVD

Do tekstu pracy załączona została płyta DVD z następującą zawartością:

- plik **/praca-dyplomowa.pdf** - tekst pracy dyplomowej,
- katalog **/projekt/** - zawiera wszystkie pliki wykonanego projektu,
- katalog **/oprogramowanie/** - zawiera oprogramowanie wymagane do uruchomienia projektu. W szczególności są to:

// todo: uzupełnić

- katalog **/program/** - program,

Bibliografia

- [1] engmrk.com. *Module 22 – Implementation of CNN Using Keras*.
<https://engmrk.com/module-22-implementation-of-cnn-using-keras/>.
- [2] Francois Chollet. *Deep Learning with Python*. 2018.
- [3] Jacob M. Williams. *Deep Learning and Transfer Learning in the Classification of EEG Signals*. 2017.
- [4] Marvin Minsky and Seymour Paper. *Perceptrons*. 1969.
- [5] futureoflife.org. *Benefits & risks of artificial intelligence*.
<https://futureoflife.org/background/benefits-risks-of-artificial-intelligence>.
- [6] searchenterpriseai.techtarget.com. *Machine learning (ML)*. <https://searchenterpriseai.techtarget.com/definition/machine-learning-ML>.
- [7] Yoshua Bengio Ian Goodfellow and Aaron Courville. *Deep learning*. Book in preparation for MIT Press, 2016.
- [8]
- [9] Andrew Lim Pierre Thodoroff, Joelle Pineau. *Learning Robust Features using Deep Learning for Automatic Seizure Detection*. 2016.
- [10] Emad-ul-Haq Qazi Ihsan Ullah, Muhammad Hussain and Hatim Aboalsamh. *An Automated System for Epilepsy Detection using EEG Brain Signals based on Deep Learning Approach*.
- [11] Nick Hershey. *Detecting Epileptic Seizures in Electroencephalogram Data*.